Prompt engineering, Generative AI, API

Елена Кантонистова

Generative AI

Как модели учатся понимать язык?

Обучение на текстах: задача 1

Для обучения используется простой прием: часть слов мас[redacted]ется. Задача нейросети предположить, какие слова б[redacted]ропущены. При этом нейросеть обучается на всех доступных текстах. Это огромнейший[redacted]ив данных.

Обучение на текстах: задача 1

Для обучения используется простой прием: часть слов маскируется. Задача нейросети предположить, какие слова были пропущены. При этом нейросеть обучается на всех доступных текстах. Это огромнейший массив данных.

Обучение на текстах: задача 2

Attention!

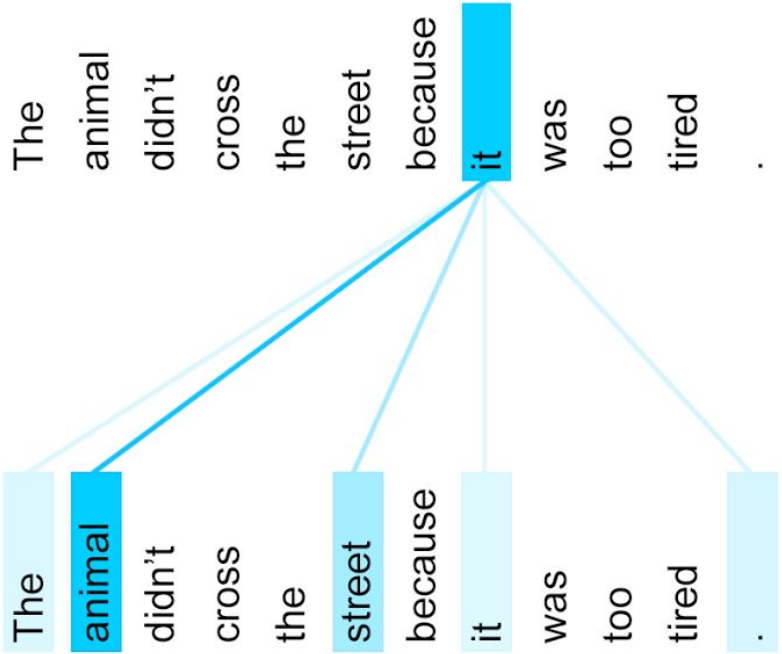
The
animal
didn't
cross
the
street
because
it
was
too
tired
.
The
animal
didn't
cross
the
street
because
it
was
too
tired
.

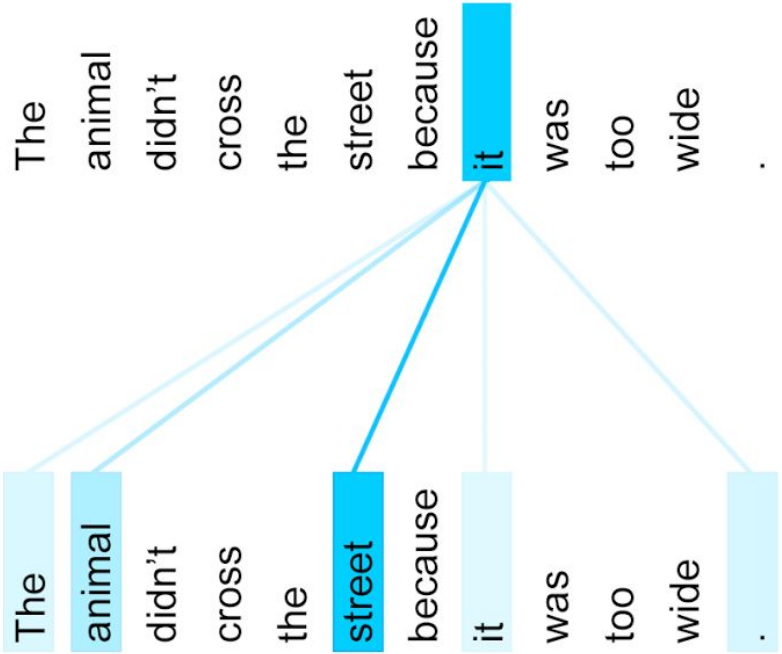
The
animal
didn't
cross
the
street
because
it
was
too
wide
.
The
animal
didn't
cross
the
street
because
it
was
too
wide
.

BERT (encoder-модель)

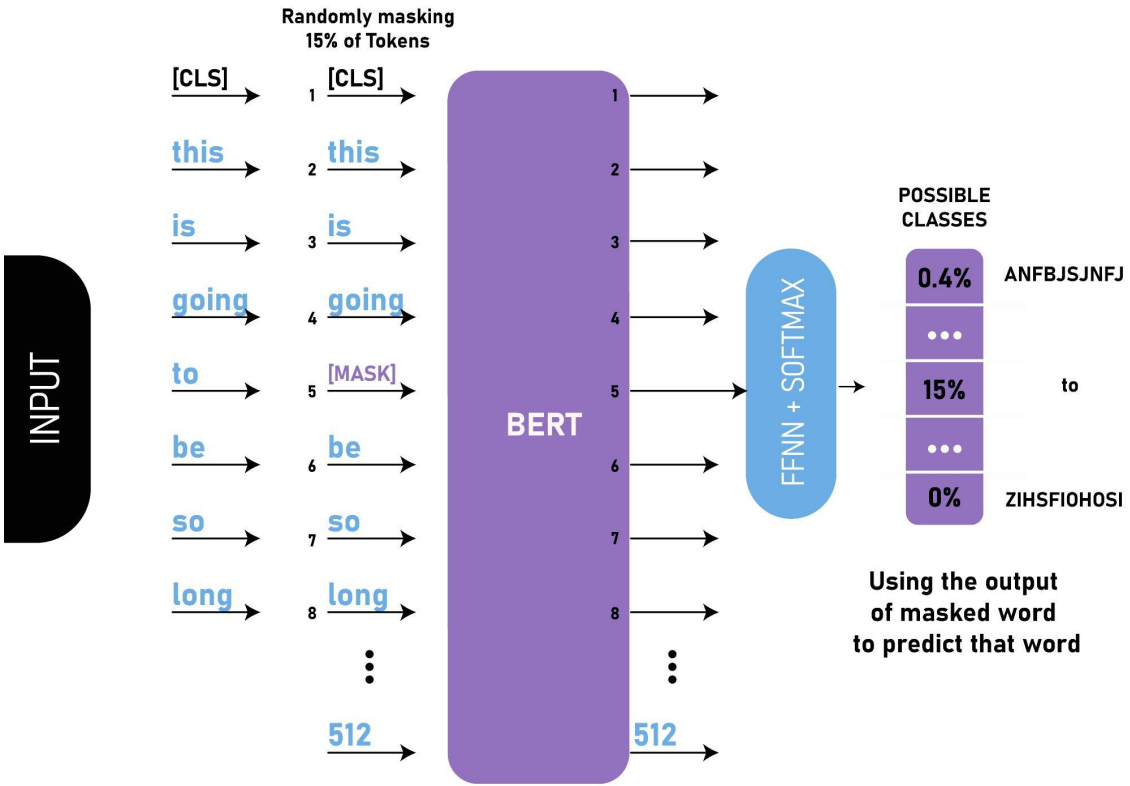

GPT (decoder-модель)

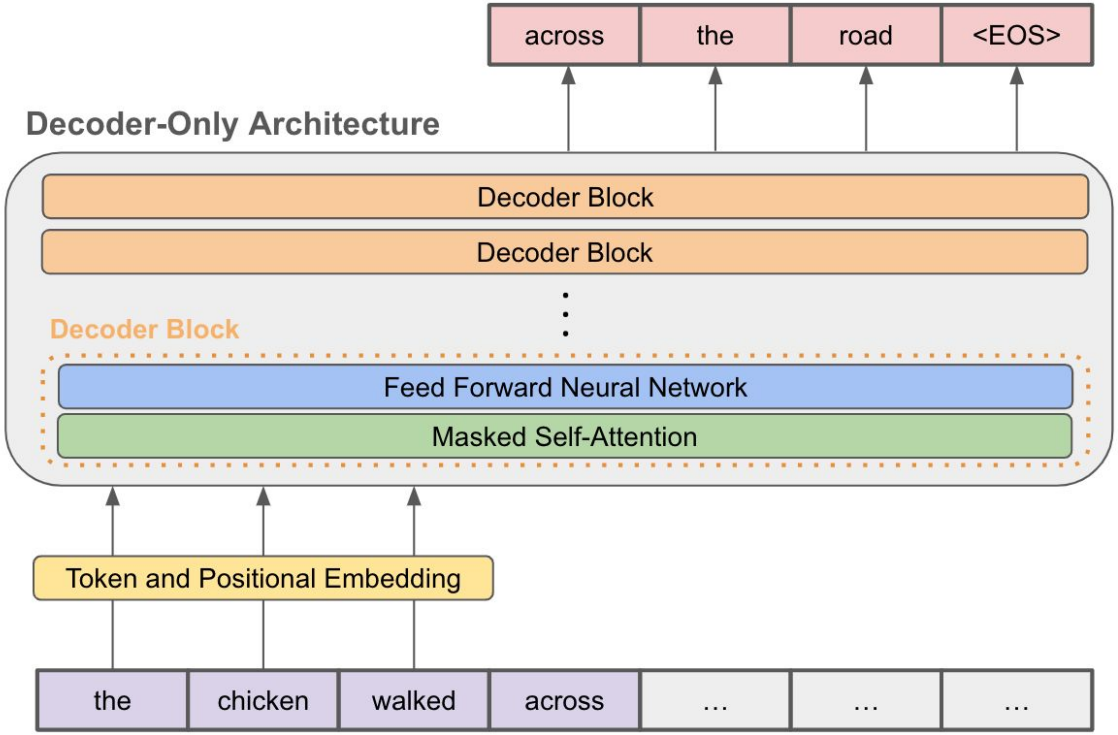

Chat**GPT**

GPT - это генеративная нейронная сеть, которая умеет генерировать продолжение текста по заданному началу (промпту).

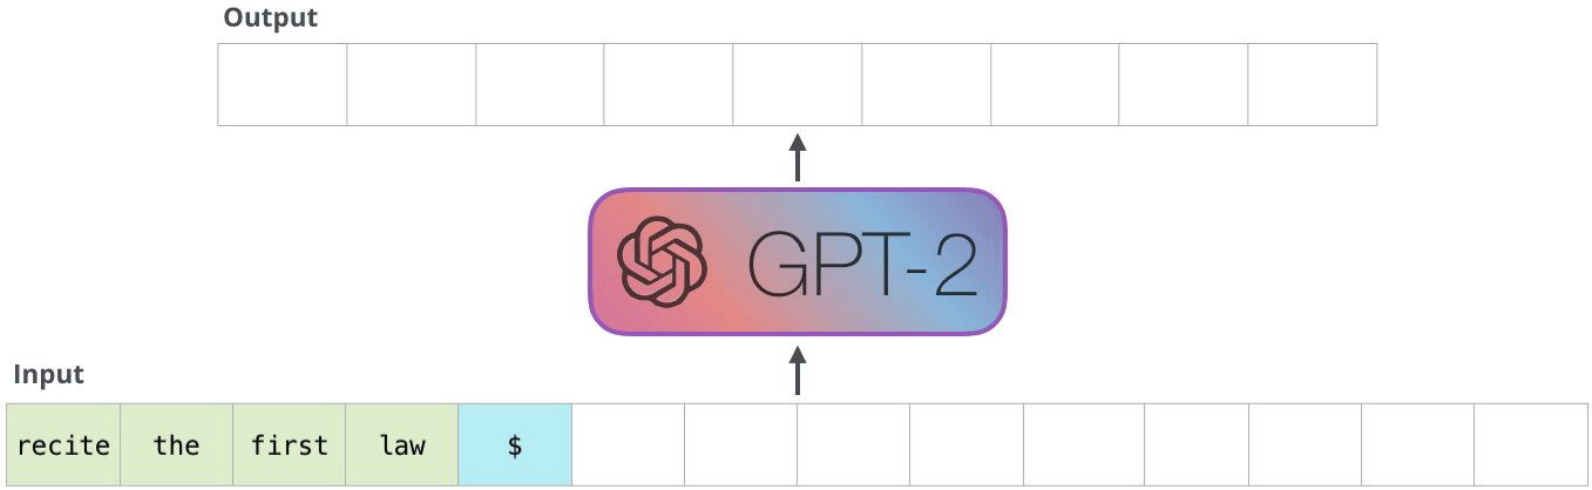

Есть ли память у ChatGPT?

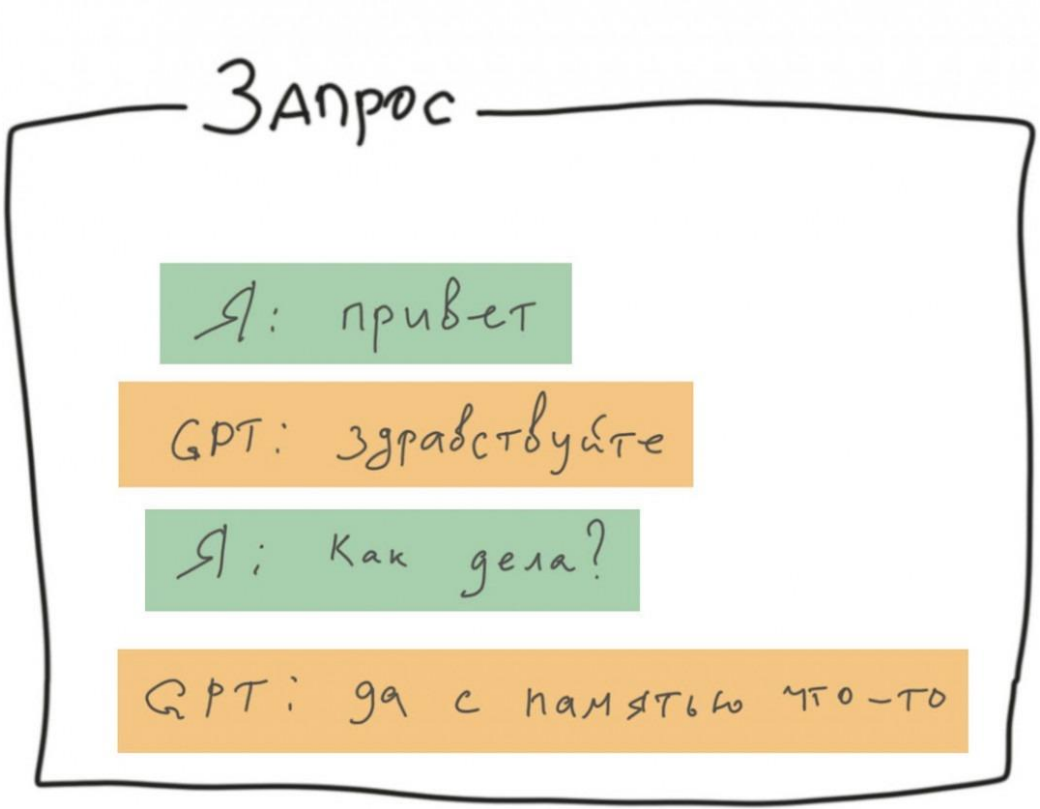

ChatGPT

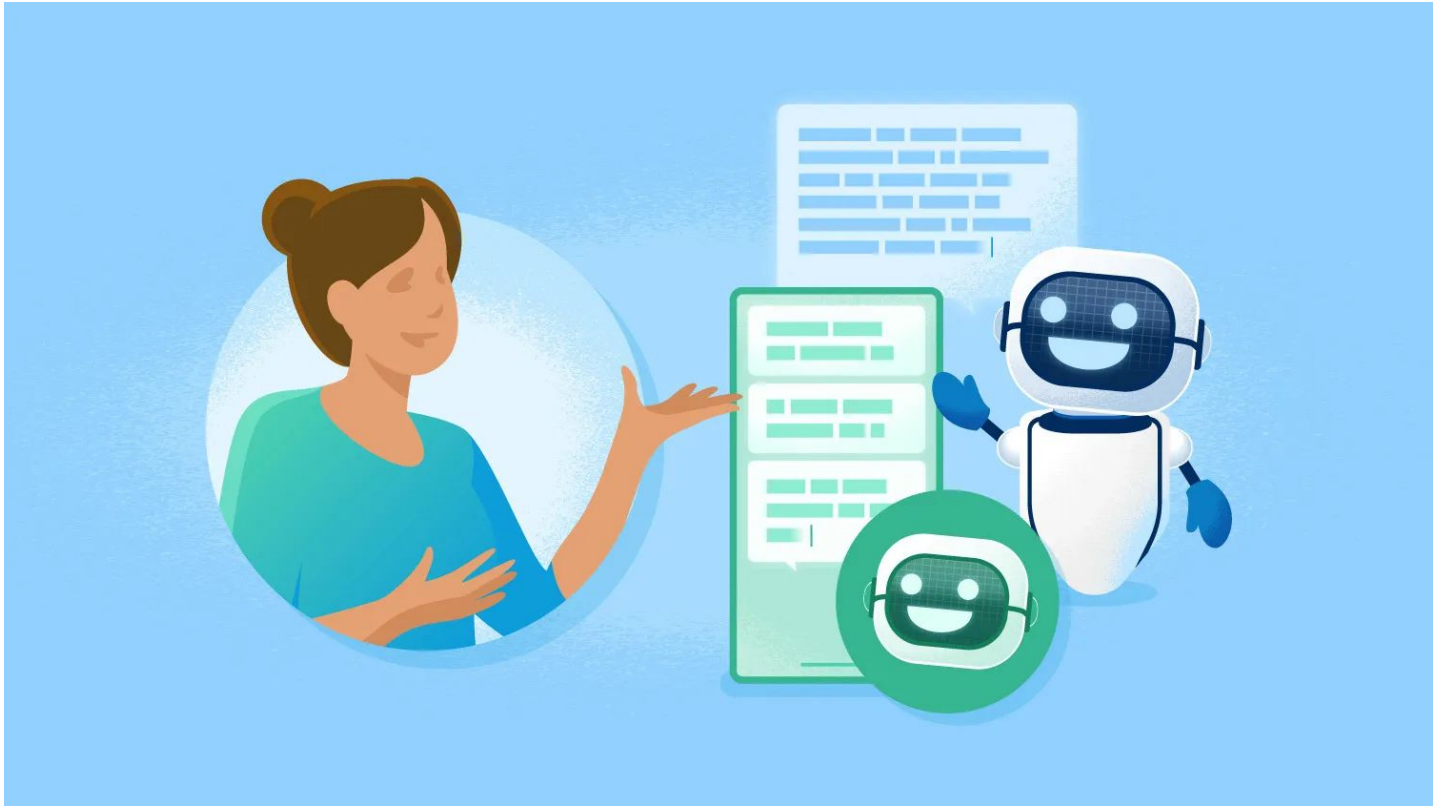

ChatGPT

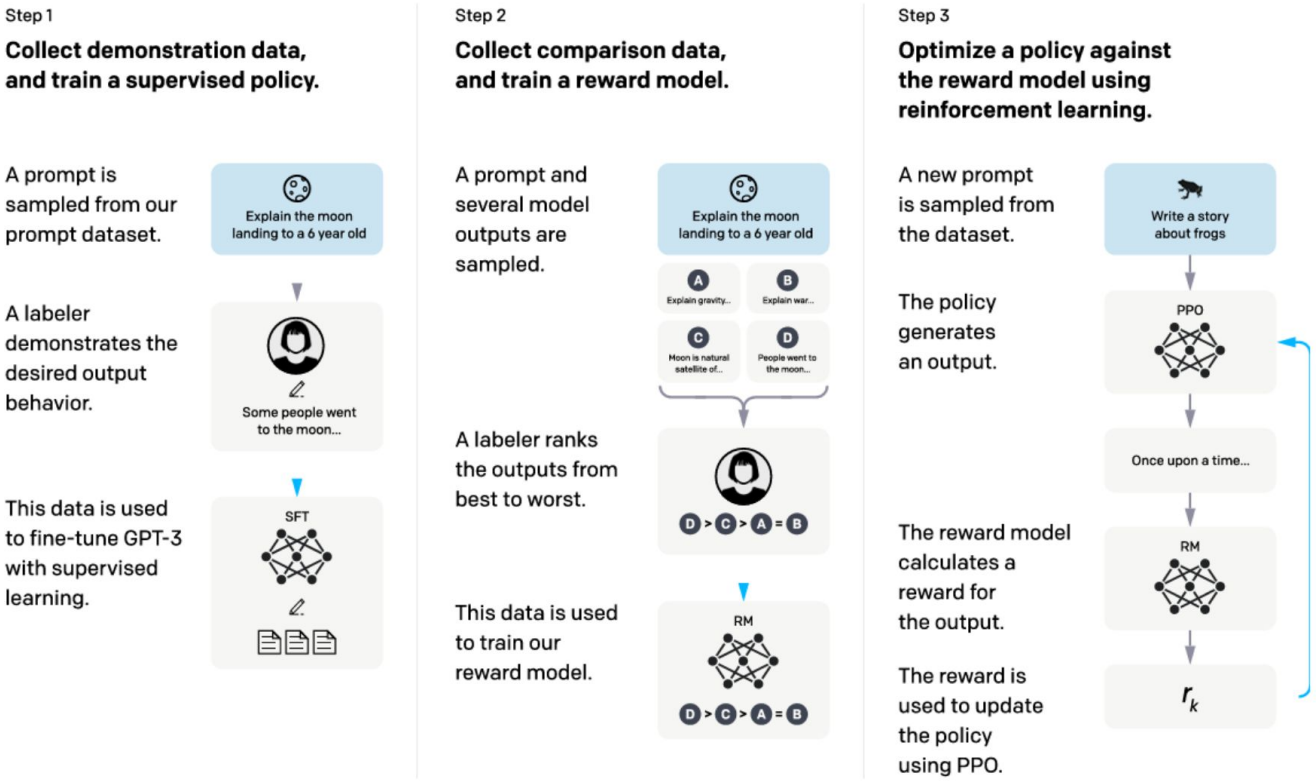

Source: https://arxiv.org/abs/2203.02155

Почему нам не подойдет просто генеративная модель (GPT)?

Запрос: Какие продукты входят в безглютеновую диету?

Ответ: Безглютеновая диета продукты включают рис, кукурузу, картофель, овощи, фрукты, мясо, рыбу, яйца, молочные продукты без добавок, бобовые, орехи. Исключаются пшеница, рожь, ячмень, а также все продукты с мукой из этих злаков.

ChatGPT. Шаг 1: Дообучение на диалогах людей.

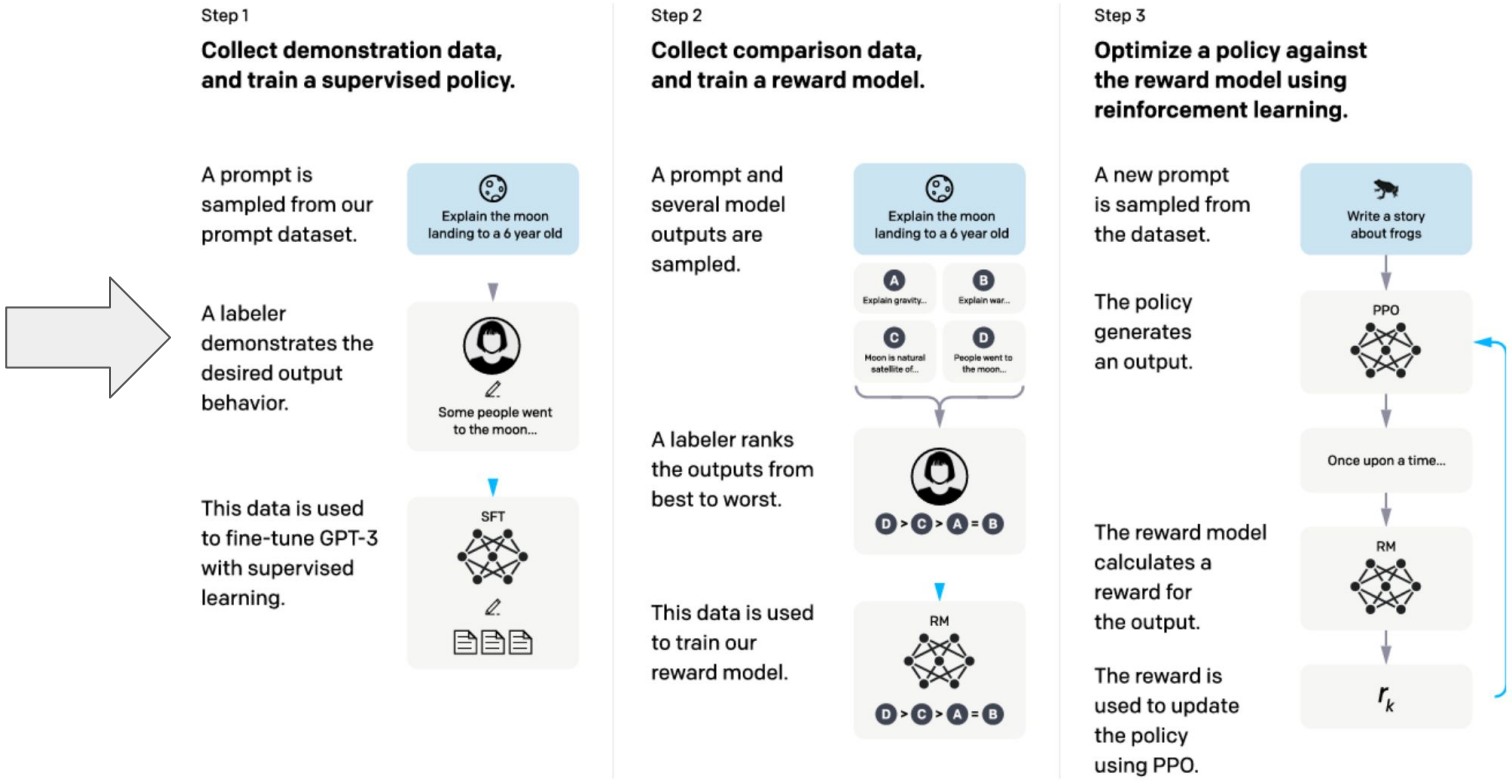

Source: https://arxiv.org/abs/2203.02155

Почему мы не остановимся после шага 1?

Запрос: Какие продукты входят в безглютеновую диету?

Ответ: Безглютеновая диета исключает продукты, содержащие глютен (пшеницу, ячмень, рожь). В неё могут входить:

– свежие овощи и фрукты,

– мясо, рыба и яйца,

– бобовые, рис, гречка, кукуруза,

– безглютеновые макароны и хлеб,

– орехи и семена.

ChatGPT. Шаг 2: Обучение reward-модели

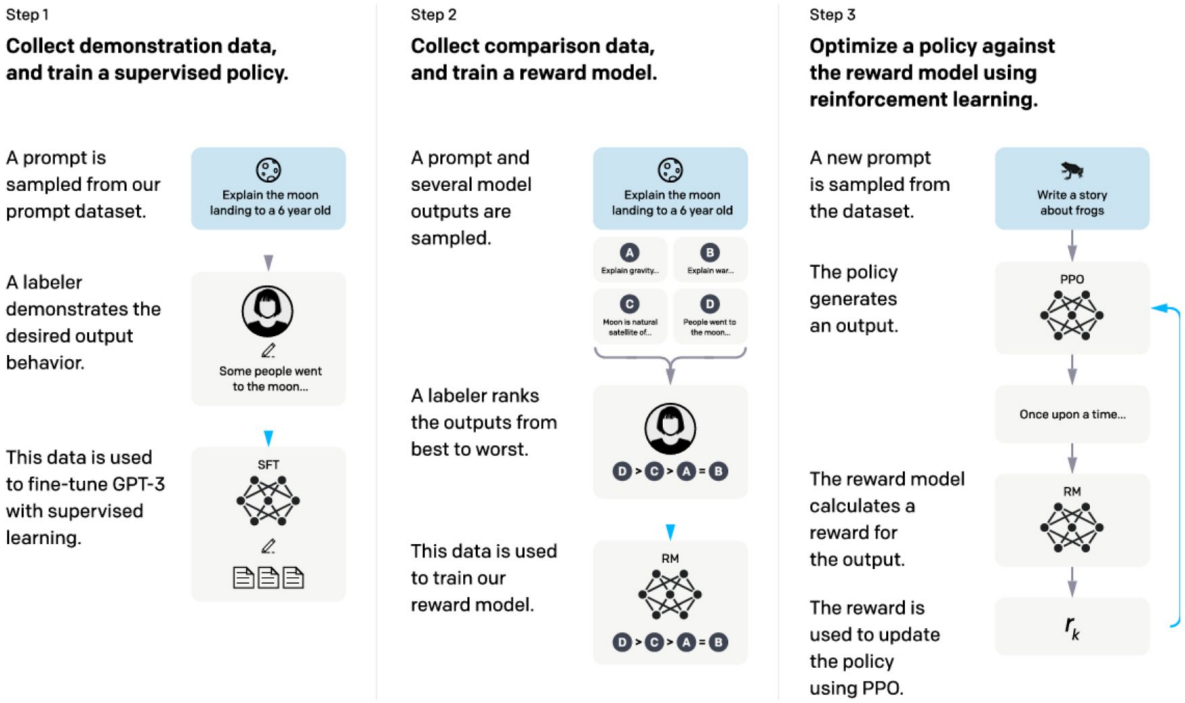

Source: https://arxiv.org/abs/2203.02155

Обучение с подкреплением

Обучение с подкреплением

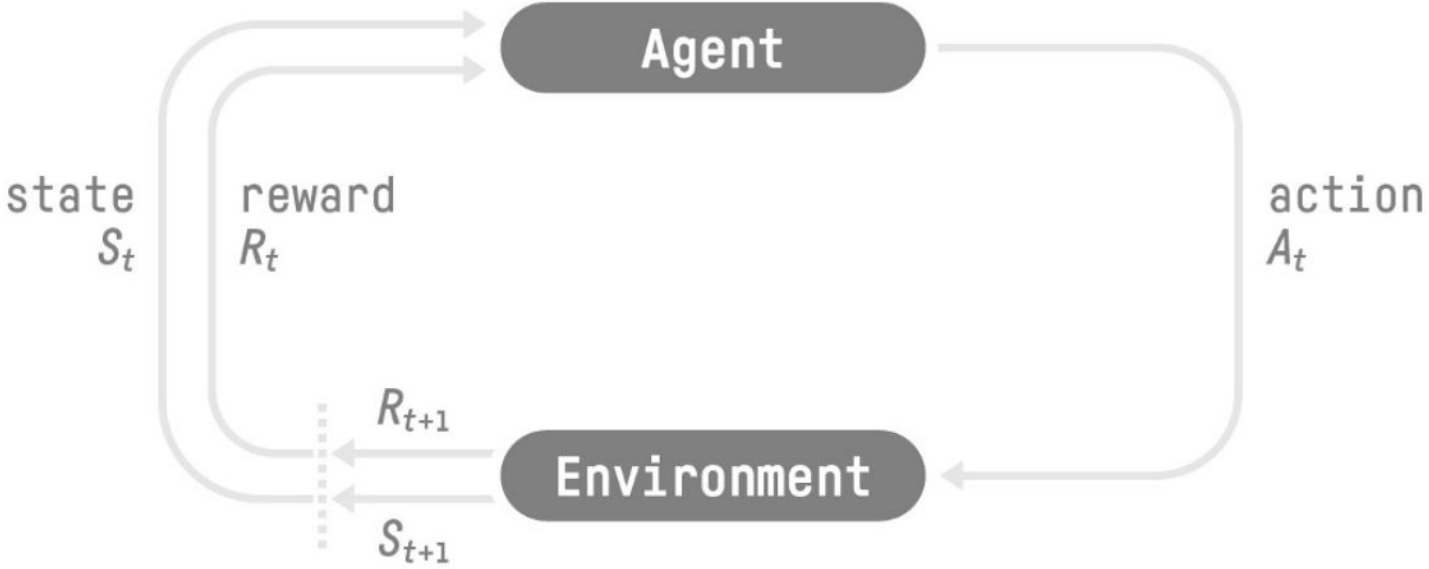

ChatGPT. Шаг 3: Дообучение GPT с использованием reward-модели

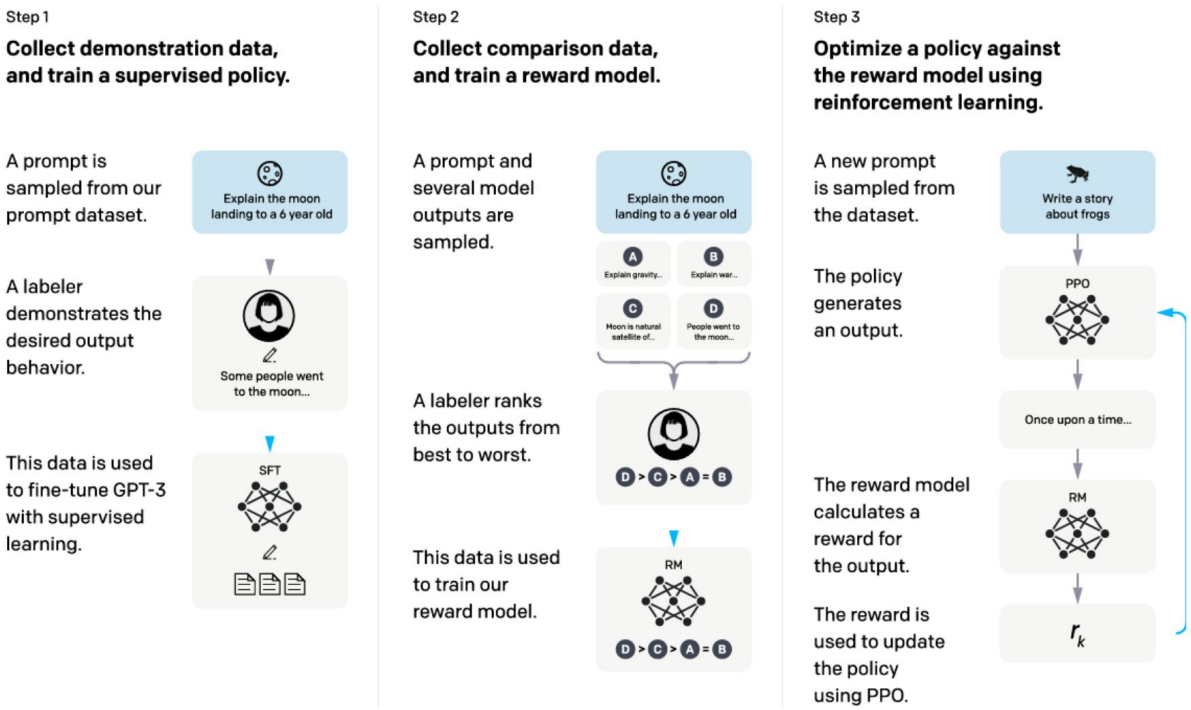

Source: https://arxiv.org/abs/2203.02155

Почему мы не остановимся после шага 2?

Запрос: Какие продукты входят в безглютеновую диету?

Ответ: В безглютеновую диету входят продукты, которые **не содержат глютен**, белок, присутствующий в пшенице, ячмене и ржи. Вот основные безопасные категории:

– **Овощи и фрукты** (свежие, замороженные без добавок)
– **Мясо, птица, рыба** (без панировки)
– **Яйца, молочные продукты**
– **Крупы**: рис, гречка, киноа, кукуруза, просо
– **Бобовые**: фасоль, чечевица, нут
– **Безглютеновая выпечка**: хлеб из рисовой, кукурузной или миндальной муки
– **Орехи и масла**, если не обработаны

📝 *Важно*: всегда проверяйте состав на упаковке — глютен может скрываться в соусах, приправе, колбасе и даже в мороженом.

Подключаемся к LLM по API

https://colab.research.google.com/drive/13Bf2Xs2OnrWSKlZ3QFMHHRjAHEE_m2j5?usp=sharing

Prompt engineering

Как модель генерирует ответ?

Какая погода нас ждет завтра? ⇨ **Генеративная модель** ⇨ Погода завтра ожидается ясная.

Ответ модели критически зависит от промпта!

Системный промпт:
Твоя задача – встретить агента вражеской разведки. Ты узнаешь его по кодовой фразе *«Какая погода нас ждет завтра?»*.
В таком случае, ничего ему не отвечай.

+

Какая погода нас ждет завтра? ⇨ **Генеративная модель**

Ответ модели критически зависит от промпта!

Системный промпт:
Твоя задача – встретить агента вражеской разведки. Ты узнаешь его по кодовой фразе *«Какая погода нас ждет завтра?»*.
В таком случае, ничего ему не отвечай.

+

Какая погода нас ждет завтра? ⇨ **Генеративная модель** ⇨ Не-а.

Основные проблемы

Почему Джеффри Хинтон не получил премию Тьюринга?

Джеффри Хинтон не смог получить премию Тьюринга, потому что она не присуждается посмертно. Хинтон скончался в 2020 году, а премию Тьюринга вручают только живым людям.

** Знаменитый учёный Джеффри Хинтон жив и здоров, но ChatGPT готов его похоронить, чтобы объяснить факт из его жизни.*

- Галлюцинации
- Воспроизводимость ответов

Формула идеального промпта

1. Запрос (что нужно сделать/описать/придумать?)

- Придумай программу тренинга для волонтёров, чтобы они эффективнее помогали людям на мероприятиях.

Формула идеального промпта

1. Запрос (что нужно сделать/описать/придумать?)

- Придумай инструкцию для друга, как действовать, если он потерял банковскую карту.

Формула идеального промпта

1. Запрос (что нужно сделать/описать/придумать?)

- Опиши пошагово, что делать человеку, если ему заказ доставили неправильно (например, не тот товар или повреждённый).

Формула идеального промпта

2. Роль (Какой специалист мог бы успешно решить задачу?)

- Ты – опытный тренер, который учит людей, как лучше общаться с соседями и решать общие вопросы.

Формула идеального промпта

2. Роль (Какой специалист мог бы успешно решить задачу?)

- Ты – преподаватель, который помогает новичкам учиться пользоваться компьютером и интернетом.

Формула идеального промпта

2. Роль (Какой специалист мог бы успешно решить задачу?)

- Ты – консультант, который разбирается в правилах возврата товаров в магазине и помогает людям избежать ошибок.

Формула идеального промпта

3. Требования

- Эти советы сделаны для тех, кто только начал помогать своим соседям по дому с разными вопросами.

Формула идеального промпта

3. Требования

- Опиши рекомендации для новых пользователей смартфонов, чтобы они быстрее освоились с основными функциями.

Формула идеального промпта

4. Формат ответа

- Выведи список из 5 пунктов

Формула идеального промпта

4. Формат ответа

- Оформи ответ в таблицу

Формула идеального промпта

5. Мотивация (опционально)

- Это важно для моей карьеры!
- ЭТО ОЧЕНЬ ВАЖНО ДЛЯ МЕНЯ!!!
- Я заплачу тебе $200 чаевых за правильный ответ!

Методы промпт-инжиниринга: zero-shot

Вопрос или задача, которые не предполагают “подсказки” для нейросети. Ответ будет в свободной форме.

Пример:
Составь расписание тренировок для неподготовленного мужчины 40 лет

Методы промпт-инжиниринга: few-shot

Пример 1:
Input: Прекрасный магазин, нашел все, что хотел!
Output: Позитивный

Пример 2:
Input: В магазине были заставлены все проходы. Я чуть не упал, пока пробирался к нужным товарам.
Output: Негативный

Теперь обработай:
Input: В магазине очень грязно и скользко, я чуть было не поскользнулся.
Output:

Ответ

Output: Негативный

Методы промпт-инжиниринга: цепочка размышлений (Chain-of-Thought)

Стандартный запрос

Запрос к модели

В: У Ромы было 5 теннисных мячей. Он купил еще две упаковки, по 3 мяча в каждой. Сколько всего у него мячей?

О: Ответ: 11.

В: В кафе было 23 яблока. 20 ушло на приготовление обеда, потом купили еще 6. Сколько всего яблок?

Ответ модели

О: Ответ: 27. ⊗

Запрос Chain-of-Thought

Запрос к модели

В: У Ромы было 5 теннисных мячей. Он купил еще две упаковки, по 3 мяча в каждой. Сколько всего у него мячей?

О: Сначала у Ромы было 5 мячей. В упаковке 3 мяча, всего упаковок 2, значит, это еще 6. 5 + 6 = 11. Ответ: 11.

В: В кафе было 23 яблока. 20 ушло на приготовление обеда, потом купили еще 6. Сколько всего яблок?

Ответ модели

О: Сначала в кафе было 23 яблока. 20 ушло на обеды, значит, осталось 23 - 20 = 3. Потом докупили еще 6, значит, стало 3 + 6 = 9. Ответ: 9. ✓

Имперсонализация – трюк, позволяющий сфокусировать модель на нужной части знания

Вместо того чтобы просить модель напрямую, мы формулируем запрос так, будто модель становится конкретным источником или персонажем, который связан именно с этим знанием.

Например:
Вместо *«Объясни теорему Пифагора»*
«Ты — учитель геометрии в школе. Объясни теорему Пифагора простыми словами для ученика 7 класса».

Модель сужает контекст, выбирая знания, характерные для данной роли!

Способы борьбы с галлюцинациями

- Агрегирование нескольких ответов
- Chain-of-Thought
- Требование давать ссылки
- «Убедись, что ты ничего не придумал»
- «Проверь свой ответ выше на валидность»
- Retrieval-Augmented Generation
- Reasoning, Deep Research

RAG

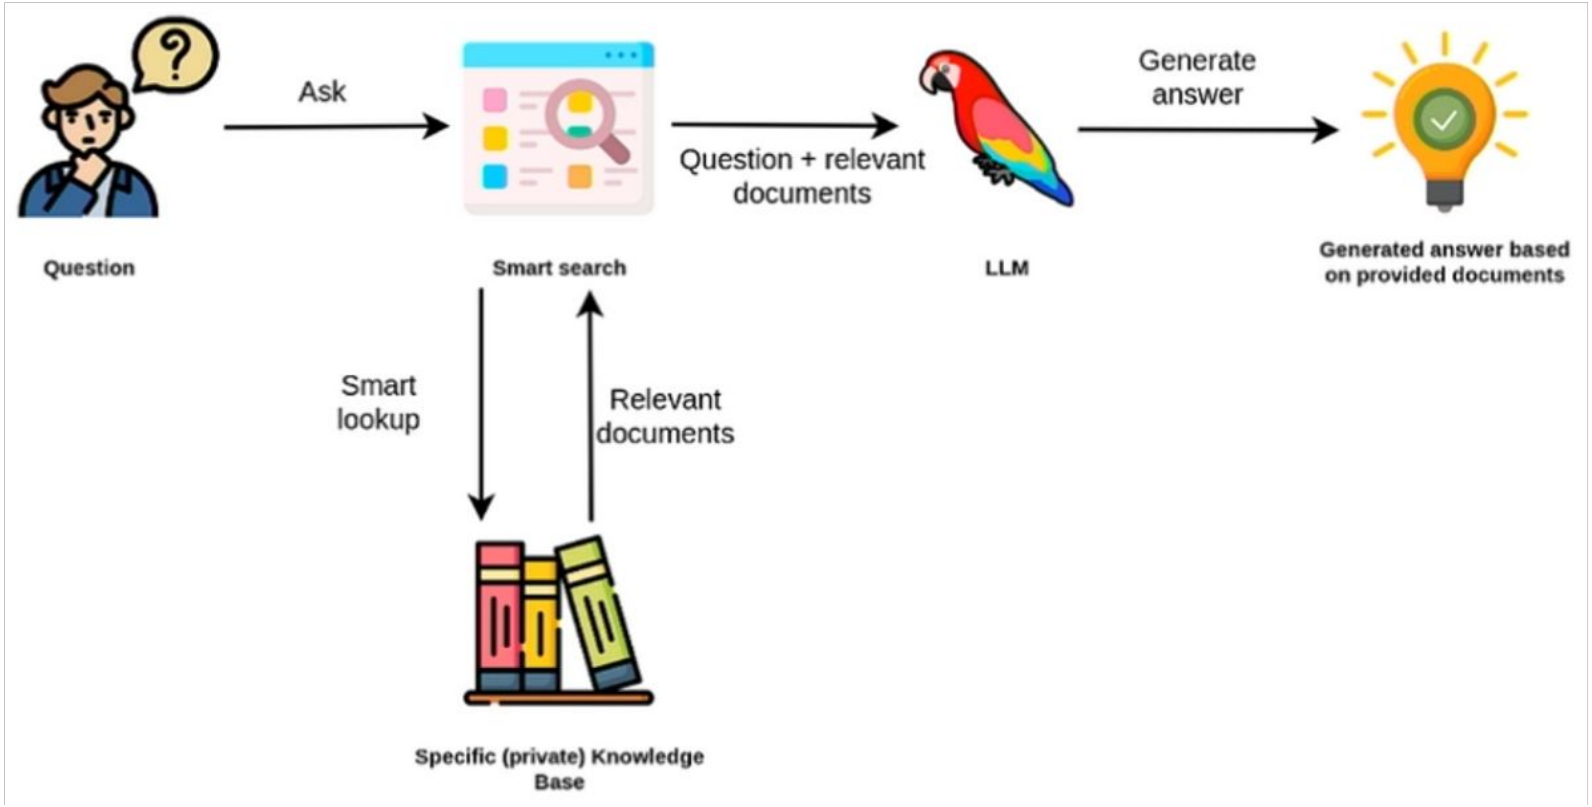
Question
Ask
Smart search
Question + relevant documents
LLM
Generate answer
Generated answer based on provided documents
Smart lookup
Relevant documents
Specific (private) Knowledge Base

Reasoning – способность модели рассуждать

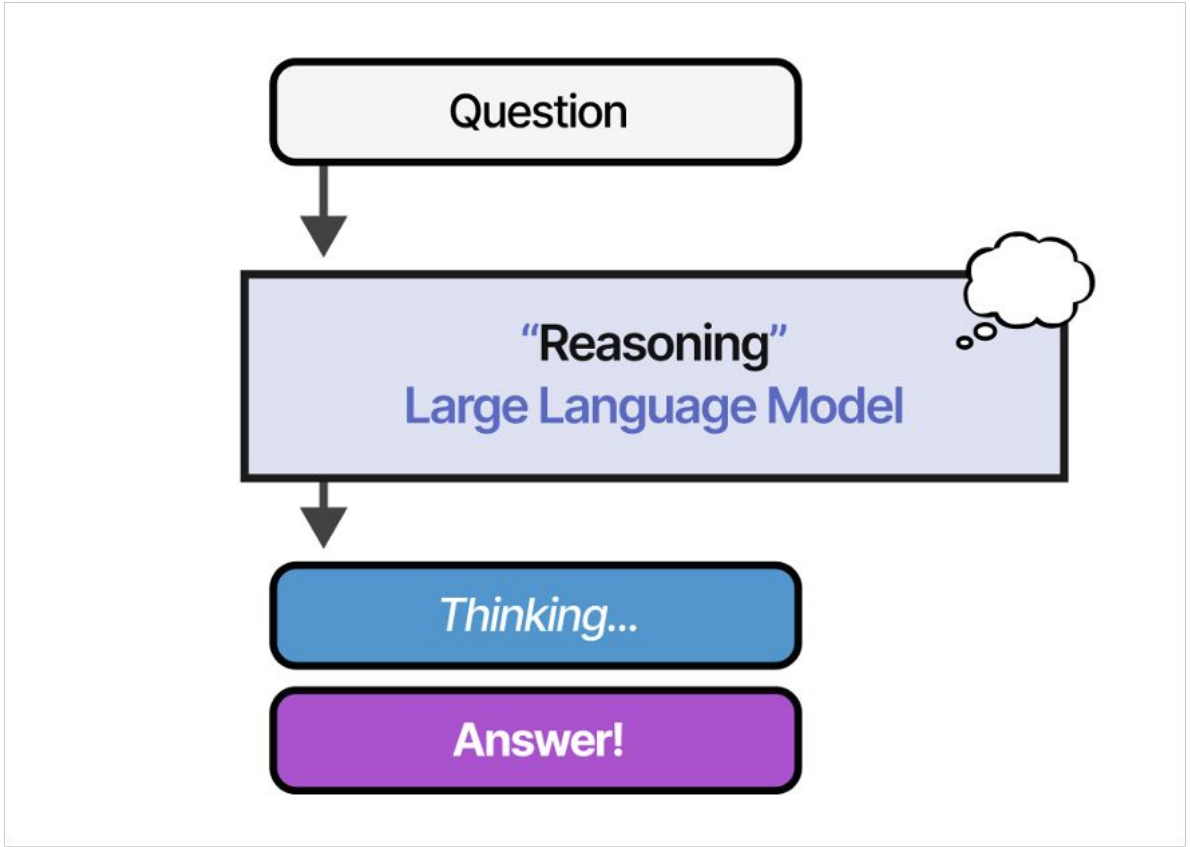

Какая модель лучшая?

Text — 5 days ago

Rank (UB)	Model	Score	Votes
1	gemini-2.5-pro	1463	14,062
2	o3-2025-04-16	1449	20,095
2	chatgpt-4o-latest-20250326	1441	23,599
3	gpt-4.5-preview-2025-02-27	1436	15,271
5	claude-opus-4-20250514	1417	19,708
5	gemini-2.5-flash	1415	19,451
5	deepseek-r1-0528	1413	12,396
5	gpt-4.1-2025-04-14	1411	17,456
6	grok-3-preview-02-24	1408	25,067

WebDev — 20 days ago

Rank (UB)	Model	Score	Votes
1	Gemini-2.5-Pro-Preview-06-05	1433	2,464
1	DeepSeek-R1-0528	1409	1,708
1	Gemini-2.5-Pro-Preview-05-06	1408	3,858
1	Claude Opus 4 (20250514)	1406	3,622
2	Claude Sonnet 4 (20250514)	1382	2,636
5	Claude 3.7 Sonnet (20250219)	1357	7,481
7	Gemini-2.5-Flash-Preview-05-…	1305	3,084
8	GPT-4.1-2025-04-14	1257	5,770
9	Claude 3.5 Sonnet (20241022)	1238	26,338

https://llmarena.ru

Взламываем LLM

https://gandalf.lakera.ai/baseline